

연구 배경

- 단일 표현과 다중 맥락

- 배경: 대부분의 순차 추천 시스템은 사용자의 다면적인 전체 구매 이력을 하나의 단일 Vector로 압축하여 다음 상품을 예측함.
- 한계:
 - 추천 시스템 학계에서는 다중 맥락을 단일 벡터로 표현하면 다중 관심사 표현이 동질화되어 구별성을 잃고 훼손을 유발함을 지적.(multi interest)
 - 특히, 이런 방식은 모델로 하여금 **과거 이력에만 의존**하여 사용자가 지금 원하는 것이 무엇인지 **수동적으로 추측**하도록 하는 것이 문제.

- 다중 맥락의 활성화 기제로서의 실시간 질의

- 해결 방향(**대화형/상호작용형** 추천의 관점)
 - 대화형/상호작용형 추천 학계에서는 이러한 수동적 유추의 한계를 부수기 위해 **실시간 질의**를 필수적인 대안으로 제시
 - 질의는 단순히 검색어가 아니라 방대한 **과거 이력 속 여러 맥락 중 현재 세션에 필요한 타겟 맥락만을 선별적으로 선택하는 능동적 활성화 기제**로 작용
- 한계:
 - 사용자의 과거 이력은 로그로 되어 있어 자연어 질의와 과거 이력 간에 매칭이 명확하지 않은 **의미론적 간극**이 존재

- LLM의 도입과 한계

- 배경: LLM을 활용해 사용자의 이력과 리뷰를 분석하여 자연어로 된 맥락을 추론하고 질의와 이력이 같은 의미 공간에 정렬하여 의미론적 간극 메움.
- 한계
 1. 온라인 실시간 연산 시, LLM의 막대한 Latency와 비용이 발생
 2. 오프라인으로 구성하더라도 기존 연구들은 단일 텍스트 프로파일로 요약해버리거나 multi로 구성하여도 특정 맥락을 활성화하지 하지 못함

➔ **본 연구의 비판점:** 이로 인해 맥락의 다양성이 훼손되거나 질의가 명확히 주어져도 맥락 활성화로 실시간 대응을 하지 못함.

문제 정의

- 단일/다중 맥락
 - 맥락 구성 시 단일로 할 경우 다양성이 훼손되고 다중으로 해도 실시간 의도에 맞게 활성화하지 못한다.
- 온라인 비용
 - 질의가 들어올 때마다 LLM을 호출하면 지연 시간과 비용 문제로 실제 서비스에 적용하기 어렵다.




- **Main Research Question:**
 - 어떻게 하면 사용자의 다중 맥락 기억을 실시간 질의와 정렬하여, 온라인 LLM 연산 없이 추천 모델의 탐색 과정 자체에 개입할 수 있을까?


제안 방법론

offline
online

0. SASRec 학습



1. Intent Memory Bank Construction




2. Training

Module 2.1




Module 2.2




Module 2.3 + 학습 1

Contrastive learning (InfoNCE)




backpropagation

Module 2.3 + 학습 2




3. Intent Activation & Base model Steering

Module 3.1



매칭된 메모리

Module 3.2



$$\text{최종 Loss } L = L_{retrieval} + \alpha \cdot L_{align}$$

제안 방법론 - Offline

- **모듈 1: Intent Memory Bank Construction**

- 사용자의 구매 리뷰와 상품 메타데이터를 LLM이 한꺼번에 읽고 귀납적으로 K개 intent memory 생성
- 리뷰 다양성 기반으로 $K \in [2, k]$ 자동 결정

- **모듈 2: Training**

- 2.1. Pseudo Query Generation

- 구매 리뷰를 구매 전 검색 질의 형태로 변환
- 예시) 제가 본 스릴러 중에 가장 재밌어요 → 가장 재미있는 스릴러 영화 추천해줘

- 2.2 Query-Memory Alignment

- LLM-as-a-judge로 쿼리와 메모리의 positive pair 설정하여 질의와 선정된 메모리로 학습 데이터셋 구축

- 2.3 Training

- 학습1: 단독학습 → Query-Memory Alignment Encoder Train

- ✓ 질의-메모리 간의 텍스트 공간 정렬 및 InfoNCE를 활용한 Contrastive learning
- ✓ InfoNCE: positive pair의 유사도를 극대화하고 negative pair의 유사도를 최소화하도록 학습시키는 Loss function

$$\mathcal{L}_{align} = -\log \frac{\exp(\text{sim}(\mathbf{h}_q, \mathbf{h}_{m^+})/\tau)}{\exp(\text{sim}(\mathbf{h}_q, \mathbf{h}_{m^+})/\tau) + \sum_{m^-} \exp(\text{sim}(\mathbf{h}_q, \mathbf{h}_{m^-})/\tau)}$$

- 학습2: 하이브리드 동시 학습

1. Encoder Train: 기존 alignment라는 목표를 위한 지식 보존 및 미세조정(low learning rate)
2. Intent-conditioned Retrieval Train: modality gap 해소 및 SASRec의 기존 지식 + 추천 방향 제어

- ✓ $h_{intent} = \text{MLP}(h_{query}, h_{memory})$ 를 SASRec prefix로 주입해 후보 생성까지 학습 $\mathcal{L}_{retrieval} = -\log P(v_{N+1} | \mathbf{E}_{input})$

- 최종 손실 함수: $\mathcal{L} = \mathcal{L}_{retrieval} + \alpha \cdot \mathcal{L}_{align}$

제안 방법론 - Online

- **모듈 3: Intent Activation & Base Model Steering**
 - 3.1 Intent Activation
 - 사용자의 실제 질의가 입력되면 유사도가 가장 높은 메모리를 선택하여 h_{intent} 를 즉시 생성
 - 3.2 Base Model Steering
 - $[h_{intent}, item_1, item_2, \dots, item_N] \rightarrow \text{SASRec} \rightarrow$ 후보 생성
 - h_{intent} 가 prefix로 작용함으로써 attention이 현재 맥락을 참조해 탐색 방향 자체를 steering
 - Reranking이 아닌 탐색 단계부터 intent 반영

로직 인사이트

- LLaVA 기반 표현 공간 간 gap 극복

- LLaVA란

- 시각(Vision) 모델과 거대 언어 모델(LLM)을 결합하여, 이미지를 보고 텍스트로 답하는 최신 멀티모달 AI 아키텍처.
 - 시각 인코더와 언어 모델을 처음부터 새로 섞어 학습하지 않고 그 사이에 단순한 선형 계층(MLP)을 두어 이미지 공간을 텍스트 공간으로 **Projection**.


- 우리 연구 적용 로직

- **인사이트 1) Modality Bridging**

- ✓ 서로 완전히 다른 수학적 차원(차원 A → 차원 B)을 연결할 때, **중간에 Translation 역할을 하는 Projector(MLP)를 배치하는 구조적 아이디어** 차용.

- **인사이트 2) 비대칭 튜닝 전략**

- ✓ 기존 모델(시각/언어)의 파라미터는 Freeze하거나 극소의 학습률로 보존하고, **MLP만 강하게 학습(더 높은 learning rate)시켜 기존 지식의 붕괴(Catastrophic Forgetting)를 막는 훈련 방식** 차용. **인사이트 2**



Contribution

- **Contribution 1) 문제 재정의**
 - 기존 추천은 다양한 구매 맥락을 하나로 뭉개고 실시간 질의 맥락을 반영하지 못한다.
 - 본 연구는 리뷰 기반 다중 의도 기억을 실시간 질의와 정렬해, 온라인 LLM 없이 후보 생성을 steering하는 문제로 재정의한다.
- **Contribution 2) 구매 리뷰 기반 의도 메모리**
 - 구매 리뷰에서 LLM이 귀납적으로 K개의 해석 가능한 맥락 기억을 생성하여 다중 관심사 임베딩의 블랙박스 한계와 LLM 프로파일의 단일 표현 한계를 동시에 해결한다.
 - 다중 프로파일을 정적 feature로 쓰는 기존 LLM-multi-aspect 연구(ProEx 등)와 달리, 실시간 질의로 조건부 활성화되는 단위로 설계
- **Contribution 3) 질의-메모리 정렬 학습**
 - 잘못된 메모리를 대조 학습의 부정 신호로 삼아 인코더를 학습한다.
- **Contribution 4) 맥락 기반 추천 탐색**
 - 학습된 의도 벡터를 SASRec prefix로 넣어 후보 생성 단계부터 맥락을 반영한다.
 - Reranking이나 feature concat이 아니라 후보 생성 과정 자체를 조종한다는 점에서 기존 LLM-rec과 다르다

APPENDIX: 활용 데이터셋

- **Amazon Review**

- Amazon 실제 사용자 리뷰와 상품 메타데이터로 구성된 대규모 데이터셋
 - 리뷰: 평점, 리뷰 텍스트, 작성 시점, 사용자-상품 interaction
 - 상품: 상품명, 카테고리, 설명, 가격, 브랜드, 관련 상품 정보 등

- **Amazon-C4**

- Amazon Reviews 데이터로 만든 complex product search 평가 데이터셋
 - 생성 방식: 5점 리뷰와 해당 리뷰의 상품 데이터를 LLM에 입력하여 해당 상품을 찾기 위한 자연어 검색 context로 제작
 - 예시)

query	Item_id	User_id
I need something that can entertain my kids during bath time. It should be able to get messy, like smearing peanut butter on it.	B07DKNN87F	AEIDF5SU5ZJIQYDAYKYKNJBBOOFQ

- 리뷰를 쿼리로 만드는 모듈을 대체할 수 있을지 확인 필요
 - ✓ Amazon review 로그와의 aggregation 가능 여부